## 資訊檢索與文字探勘導論 作業一

會計四 B06702064 林聖硯

- 1. 執行環境 Anaconda Spyder
- 2. 程式語言 Python 3.6.8
- 3. 執行方式
  - (1) 需要 import nltk 套件,使用 pip install nltk
  - (2) 打開 py 檔並執行 89-91 行即可得到 result. txt (txt 檔及 stopword 檔已經寫死在程式裡)

```
87
88 #需要執行的部分
89 text = get_text()
90 text_final = text_preprocessing(text)
91 save_result(text_final)
92
```

- 4. 作業處理邏輯說明
  - (0)import 套件 由於後面需要使用 PorterStemmer,故在此先從 nltk 導入

```
1 from nltk.stem.porter import PorterStemmer
2
```

(1)讀檔

將文本從 txt 檔讀入並回傳

## (2)切文本

將文本去除換行符號(使用 strip),並且用空白符號加上 python 內建的 split 將字與字分開,最後再將一些簡寫先還原(如's 變成 is 等等)

(3)刪除標點符號、將子母縮成小寫

此處函數在將文本中的詞去除標點符號並且將全部字母縮成小寫

(4)stemming

將昱處裡的文本使用 nltk 中的 porter's algorithm 套件做 stemming

## (5) 將停用字去除

(6)將上述所有的前處理步驟打包並且回傳最後的文本(型態是 list,每一個元素代表一個處理完的詞)

```
def text_preprocessing(text_tokenized):
    text_tokenized = tokenize_text(text)
    text_no_del = delete_delimiters(text_tokenized)
    text_lower = lowercase_words(text_no_del)
    text_stemmed = stemming_word(text_lower)
    text_final = remove_stopwords(text_stemmed)
    return text_final
```

## (7) 將處理好的文本存成 txt 檔

```
def save_result(text_final):
    Save the result as a txt file
    with open('result.txt', 'w') as f:
        for item in text_final:
            f.write("%s\n" % item)
```