資訊檢索與文字探勘導論 作業四

會計四 B06702064 林聖硯

- 1. 執行環境 Anaconda Spyder
- 2. 程式語言
 Python 3.6.8
- 3. 執行方式
 - (1) 需要 import numpy 及 python 內建的 copy 模組 使用 pip install numpy
- (2) 名為「result」的子資料夾內放入作業二得到每篇文章 unit-tfidf 的結果(名稱是 doc1.txt 到 doc1095.txt)
- (3) 執行 120 到 130 行即可得到結果(三個文件分別存在與 py 檔同一個資料夾內)

```
num_doc = 1095

tfidf_matrix = generate_tfidf_matrix(num_doc)

similarity_matrix = get_cosine_sim_matrix(num_doc, tfidf_matrix)

#clustering

K_list = [8, 13, 20]

for K in K_list:
    available_cluster = get_available_cluster_list(num_doc)
    similarity_matrix_2 = copy.copy(similarity_matrix)

result = HAC(K, num_doc, similarity_matrix_2, tfidf_matrix, available_cluster)

save_result(K, result)
```

4. 程式處理邏輯

(0) import 需要套件

```
import numpy as np
import copy
```

(1) retrieve_index_and_tfidf_from_txt

從 txt 檔案內拿出每個字的 index 以及相對應的 tfidf

(2) generate_tfidf_matrix

將上一步得到得 tfidf 向量,存到 numpy array 裡面做出 tfidf matrix

```
#14299是從pa2得來的bag-of-word model的長度

def generate_tfidf_matrix(num_doc, len_BOW = 14299):
    tfidf_matrix = np.zeros((num_doc, len_BOW))
    for doc_index in range(1, num_doc + 1, 1):
        indexes, unit_tfidf = retrieve_index_and_tfidf_from_txt(doc_index)
        count = 0

for index in indexes:
        #print(index, unit_tfidf[count])
        tfidf_matrix[doc_index - 1][index - 1] = unit_tfidf[count]
        count += 1
    return tfidf_matrix
```

(3) get cosine sim matrix

使用 tfidf matrix 計算文章間的 cosine similarity, 並且存入 shape 為 (1095, 1095)的 matrix(稱為 similarity matrix)

-----clustering------

(1) get_available_cluster_list

製造一個程度為 1095 的 list(全部放入 1),代表還可以被 cluster 的文章。

```
56 ▼ def get_available_cluster_list(num_doc):
57     available_cluster = []
58 ▼    for i in range(num_doc):
59         available_cluster.append(1)
60     return available_cluster
```

(2) HAC 演算法

- a. result (list): 每一個元素放入文章的代碼的 list(為了使用 extend function)
 - b. 當剩下的 cluster 大於給定的 K 時就執行 HAC 演算法。
- c. index 為 similarity matrix 裡面最大的值的 row 及 column index,並以此index 來更新 available_cluster 及 similairty_matrix
- d. 這裡針對 cluster 及 cluster 之間的相似度採用 GACC(Group-average Agglomerative Clustering)

```
def HAC(K, num_doc, sim_matrix, tfidf_matrix, available_cluster):
   result = []
    for i in range(num_doc):
        result.append([i+1])
   while(sum(available cluster) > K):
        index = np.unravel_index(np.argmax(sim_matrix, axis=None), sim_matrix.shape)
        row index = index[0]
        column_index = index[1]
        result[row_index].extend(result[column_index])
result[column_index] = 0
        available_cluster[column_index] = 0
        #update similarity with row_index
        for j in range(num_doc):
            if available_cluster[j] == 0:
                new_sim = 0
            elif (j == row_index):
                new_sim = 0
               new_sim = sim_gacc(j, row_index, tfidf_matrix, result)
            sim_matrix[j][row_index] = new_sim
sim_matrix[row_index][j] = new_sim
            sim_matrix[j][column_index] = 0
            sim_matrix[column_index][j] = 0
    return result
```

(3) sim_gacc

計算 gacc 相似度

```
93 v def sim_gacc(clus_iter, clus_survive, tfidf_matrix, result):
94 v ''
95 compute similarity for two documents by using gacc
96 c''
97 len_clus_iter = len(result[clus_iter])
98 len_clus_survive = len(result[clus_survive])
99 index_survive = np.array(result[clus_iter] - 1
100 index_survive = np.array(result[clus_iter]) - 1
101 sum_iter_cluster = np.sum(tfidf_matrix[index_iter], axis = 0)
102 sum_iter_survive = np.sum(tfidf_matrix[index_survive], axis = 0)
103 s = np.sum([sum_iter_cluster, sum_iter_survive], axis = 0)
104 similarity_gacc = (np.dot(s,s) - len_clus_iter - len_clus_survive) / ((len_clus_iter + len_clus_survive) * (len_clus_iter + len_clus_survive) * return similarity_gacc
```

(4) save_result

將結果存入 txt 檔案內